F1 · DAY1 · WEEK3 SEMAINE 3 · JOUR 1 · FICHE 1 PARCOURS AI/ML ENGINEER

LUNDI 26 OCTOBRE 2026

Les stats du Machine Learning, appliquées à ExamPredict AI

Moyenne, médiane, écart-type, corrélation, vecteurs et matrices, puis une première prédiction testée honnêtement par backtesting. Chaque notion est énoncée, expliquée « en clair », puis appliquée à ton projet.

1. Pourquoi des stats avant le ML
2. Moyenne et médiane
3. Écart-type
4. Corrélation
5. Vecteurs, matrices, X et y
6. Le réflexe describe / corr
7. ExamPredict : la matrice des concepts
8. ExamPredict : prédire 2027
9. Qualité des données
10. Exercices corrigés
11. À savoir par cœur

---

1. Pourquoi des stats avant le ML

Un modèle de Machine Learning apprend à partir de données. S'il apprend sur des données qu'on ne comprend pas (valeurs bizarres, colonnes inutiles, trop peu d'exemples), il prédit faux, sans le dire.

> **Dans le métier**
>
> Avant d'entraîner quoi que ce soit, un ingénieur ML **regarde** ses données : il les résume en quelques chiffres. C'est l'**analyse exploratoire (a-na-lize èks-plo-ra-twar)**, souvent appelée EDA.

2. Moyenne et médiane

Définition 2.1 *(moyenne)*

La **moyenne** de n valeurs est leur somme divisée par n.

En clair : c'est le **partage équitable**. Tout le monde met ses points dans un pot commun, puis on les repartage pareil pour tous.

Définition 2.2 *(médiane)*

La **médiane** est la valeur qui sépare les données rangées dans l'ordre en deux moitiés égales. Pour un nombre pair de valeurs, c'est la moyenne des deux valeurs centrales.

En clair : c'est l'élève qui est **pile au milieu de la file**.

```
notes : 10, 12, 14, 16, 0        # un élève absent a eu 0
moyenne = 52 / 5 = 10.4          # le 0 tire tout le monde vers le bas
rangées : 0, 10, 12, 14, 16  →  médiane = 12

df["maths"].mean()     # moyenne   (point mîne)
df["maths"].median()   # médiane   (point médiane)
```

> **Proposition 2.3**
>
> La médiane résiste aux **valeurs extrêmes**, la moyenne non. Quand la moyenne et la médiane sont très différentes, il y a probablement des valeurs bizarres dans les données.

---

3. Écart-type

> **Définition 3.1** *(écart-type)*
>
> L'**écart-type** mesure la distance typique entre les valeurs et leur moyenne. En anglais : *standard deviation*, d'où `.std()` **(point esse-té-dé)**.
>
> **En clair :** les élèves sont debout autour d'un arbre (la moyenne). Petit écart-type : ils sont **collés à l'arbre**. Grand écart-type : ils sont **éparpillés dans la cour**.

CLASSE	NOTES	MOYENNE	ÉCART-TYPE
A	9, 10, 10, 11	10	≈ 0,8 (serrés)
B	0, 5, 15, 20	10	≈ 9,1 (éparpillés)

> **Dans le métier**
>
> Une colonne d'écart-type **0** a toujours la même valeur : elle n'apprend rien au modèle, on la supprime.

---

4. Corrélation

> **Définition 4.1** *(coefficient de corrélation)*
>
> La **corrélation** entre deux colonnes est un nombre entre **−1** et **+1** qui mesure à quel point elles varient ensemble de façon linéaire.
>
> **En clair :** deux amis qui marchent. **+1** : main dans la main. **0** : chacun de son côté. **−1** : quand l'un avance, l'autre recule.

```
df.corr()        # toutes les corrélations entre colonnes  (point kor)
df.corr().round(2)
```

Piège 4.2 *(corrélation n'est pas causalité)*

Les ventes de glaces et les coups de soleil sont corrélés. Ce n'est pas la glace qui brûle : la vraie cause commune, c'est la **chaleur**.

Piège 4.3 *(trop peu de points)*

Avec seulement 3 points, deux colonnes ont presque toujours l'air très corrélées (proche de ±1), **par hasard**. C'est ce qu'on a vu sur les 3 sujets du bac : des corrélations à 0,98 qui ne prouvent rien. Il faut beaucoup plus de données pour conclure.

---

5. Vecteurs, matrices, X et y

Définition 5.1

Un **vecteur** est une liste ordonnée de nombres qui décrit un objet. Une **matrice** est un tableau de nombres : des vecteurs empilés.

En clair : une ligne du tableau = la **carte d'identité en chiffres** d'un objet. Le tableau entier = la matrice.

Convention du ML

X (grand ixe) = la matrice des informations qu'on **donne** au modèle. **y (petit i-grec)** = ce qu'il doit **deviner**.

```
X = df[["revision", "telephone"]]   # 2 colonnes d'entrée
y = df["maths"]                     # la cible
X.shape   # (lignes, colonnes)   (point chêpe)
```

---

6. Le réflexe `describe` / `corr`

`df.describe()` **(point di-skraïbe)** donne d'un coup, pour chaque colonne numérique :

LIGNE	SENS
`count`	nombre de valeurs (repère les cases vides)
`mean` / `std`	moyenne / écart-type
`min` / `max`	plus petite / plus grande valeur (repère les valeurs impossibles)
`50%`	la médiane

7. ExamPredict : la matrice des concepts

Fichier `src/stats_concepts.py`. On lit les sujets du bac, on compte les concepts dans chacun, et on range le tout dans une matrice : **une ligne par examen, une colonne par concept**.

```
import pandas as pd
pd.set_option("display.max_columns", None)       # afficher toutes les colonnes
from document_loader import load_documents        # ton propre code
from analyzer import find_concepts

documents = load_documents("data/exams")          # {nom du fichier: texte}
lignes = {}
for nom, texte in documents.items():
    lignes[nom[:4]] = find_concepts(texte)         # "2024" -> {concept: nombre}

df = pd.DataFrame(lignes).T.fillna(0)             # .T retourne, fillna(0) remplit les vides
stats = pd.DataFrame({"moyenne": df.mean(), "mediane": df.median(), "ecart_type": df.std()})
print(stats.round(1))
print(df.corr().round(2))
df.to_csv("data/concepts_par_examen.csv")
```

CONCEPT	MOYENNE	MÉDIANE	ÉCART-TYPE	LECTURE
acide-base	60,3	49	24,1	le plus présent chaque année
électricité	10,3	2	15,3	une seule grosse année : la médiane dit la vérité
radioactivité	9,0	0	15,6	tombé une seule fois
optique	4,3	4	1,5	peu, mais très régulier

> **Règle 7.1** *(l'ordre compte)*
>
> Python exécute le fichier de haut en bas. Un réglage comme `pd.set_option` placé après un `print` arrive trop tard pour lui : les réglages se mettent en haut.

8. ExamPredict : prédire 2027

Fichier `src/predire_2027.py`, sur `data/chapitres_bac.csv` : 66 exercices de 2010 à 2026, regroupés en 10 familles de chapitres.

Définition 8.1 *(vote pondéré, décroissance exponentielle)*

Chaque exercice passé vote pour sa famille avec un poids `0.8 ** (année cible − 1 − année)`. L'année la plus récente pèse 1, la précédente 0,8, puis 0,64, etc. Le score d'une famille est la somme de ses votes.

En clair : les années récentes parlent plus fort, parce que le programme et les habitudes des concepteurs évoluent.

```
def predire(df, annee_cible, k=6):
    passe = df[df["annee"] < annee_cible]                    # interdit de regarder l'avenir
    poids = 0.8 ** (annee_cible - 1 - passe["annee"])       # ** = puissance
    score = poids.groupby(passe["famille"]).sum()           # le dépouillement du vote
    return score.sort_values(ascending=False).head(k)
```

Définition 8.2 *(backtesting)*

Le **backtesting** **(bak-tèss-tingue)** teste une méthode sur le passé : on se place en 2021, on prédit 2022 sans le regarder, on compare avec la réalité, et on recommence chaque année.

```
prevu = set(predire(df, annee).index)                # set = ensemble sans doublons
reel  = set(df[df["annee"] == annee]["famille"])
touches = len(prevu & reel)                           # & = intersection : les prédictions réussies
```

MÉTHODE	CHAPITRES RÉELS PRÉVUS (2022 À 2026)
6 familles au hasard	≈ 60 %
Comptage simple (tous les poids à 1)	20 / 26 = 77 %
Vote pondéré 0,8	**22 / 26 = 85 %**

PRÉDICTION 2027	SCORE
1. Mécanique	21,6 %
2. Chimie organique	19,9 %
3. Électricité	12,5 %
4. Ondes et optique	11,2 %
5. Acide-base	9,8 %
6. Cinétique chimique	8,4 %

Piège 8.3 *(le numéro de l'exercice)*

L'ordre des exercices ne suit aucune logique d'une année à l'autre. Prédire « exercice 1 = X » serait du hasard. On prédit l'**ensemble des chapitres** probables sur les deux jours.

Piège 8.4 *(score ≠ probabilité)*

Le pourcentage est la **part du score** d'un chapitre, pas la probabilité exacte qu'il tombe. Il sert à **classer** les chapitres.

9. Qualité des données

Piège 9.1 *(hallucination)*

Les chapitres de 2010 à 2026 viennent de ChatGPT. Une IA peut **inventer** ou mélanger des faits : on appelle ça une **hallucination (a-lu-si-na-sion)**. Garbage in, garbage out.

Dans le métier

On **vérifie un échantillon** avec une autre source. Ici, les vrais PDF analysés par ton propre code ont servi de contrôle : 2025 jour 1 → Nucléaire ✓ (radioactivité = 27 dans le PDF). 2026 jour 1 reste suspect (le PDF parle beaucoup de gaz et de thermodynamique). 2014 et 2023 jour 1 sont aussi à vérifier.

Éthique des données

On respecte la volonté des sites : Labolycée et L'Étudiant s'opposent à la collecte automatique (robots.txt), donc pas de scraping. Les chapitres tombés chaque année sont une information publique.

10. Exercices corrigés

Exercice 1 ★ médiane

Notes : 2, 3, 4, 100. Moyenne ou médiane : laquelle décrit le mieux la classe ?

Corrigé. Moyenne = 109 / 4 = 27,25 ; médiane = (3 + 4) / 2 = 3,5. La médiane décrit mieux la classe : le 100 est une valeur extrême (Prop. 2.3).

Exercice 2 ★ écart-type

Deux concepts ont la même moyenne de 10 apparitions. A a un écart-type de 1, B de 12. Lequel réviser en priorité ?

Corrigé. A : il tombe à peu près autant **chaque année**, il est fiable. B tombe par à-coups.

Exercice 3 ★★ corrélation

Sur 3 sujets, corrélation(mouvement, forces) = 0,98. Peut-on conclure que ces chapitres tombent toujours ensemble ?

Corrigé. Pas avec certitude : 3 points sont trop peu (Piège 4.3). C'est plausible physiquement (un exercice de mécanique mêle les deux), mais il faut plus de sujets pour l'affirmer.

Exercice 4 ★★ backtesting

Pourquoi la fonction `predire` filtre-t-elle `df["annee"] < annee_cible` ?

Corrigé. Pour ne pas regarder l'avenir. Sinon, le backtest tricherait : la méthode « connaîtrait » déjà la réponse, et sa précision serait gonflée artificiellement.

Exercice 5 ★★★ poids

Pour prédire 2027 avec un facteur 0,8, quel poids a un exercice de 2024 ?

Corrigé. 0,8 ** (2027 − 1 − 2024) = $0{,}8^2$ = 0,64.

11. À savoir par cœur

1. Avant d'entraîner un modèle, on regarde les données : `df.describe()` et `df.corr()`.
2. **Moyenne** = partage équitable. **Médiane** = valeur du milieu, qui résiste aux valeurs extrêmes.

3 **Écart-type** = valeurs serrées ou éparpillées autour de la moyenne. Écart-type 0 = colonne inutile.

4 **Corrélation** entre −1 et +1. Ce n'est pas une preuve de cause, et elle n'est pas fiable avec trop peu de points.

5 **Vecteur** = une ligne de nombres, **matrice** = le tableau. **X** = entrées, **y** = ce qu'on prédit.

6 Python lit de haut en bas : les réglages vont en haut du fichier.

7 Un **vote pondéré** donne plus de poids aux années récentes : `0.8 ** écart`.

8 Le **backtesting** teste une méthode sur le passé sans jamais regarder l'avenir. Toujours comparer au hasard.

9 Les données d'une IA peuvent être **hallucinées** : on vérifie un échantillon.

10 On respecte la volonté des sites (robots.txt) : pas de scraping là où il est refusé.
